

运营商智算中心建设思路及方案

Construction Ideas and Plans for Operator Intelligent Computing Centers

童俊杰¹, 申佳², 赫罡¹, 张奎² (1. 中国联合网络通信集团有限公司, 北京 100033; 2. 中讯邮电咨询设计院有限公司郑州分公司, 河南 郑州 450007)

Tong Junjie¹, Shen Jia², He Gang¹, Zhang Kui² (1. China United Network Communications Group Co., Ltd., Beijing 100033, China; 2. China Information Technology Designing & Consulting Institute Co., Ltd. Zhengzhou Branch, Zhengzhou 450007, China)

摘要:

人工智能训练的计算复杂度逐年猛增,所需的智能算力从每秒千万次运算增加到数百亿次,甚至进入千亿级别,促进了大规模智算中心的建设。智算中心主要满足智算算力的需求,其布局、建设及维护方案与传统的云资源池存在较大差异,当前运营商对智算中心的布局以及详细方案并没有统一的建议和参考。分析了大模型发展带来的算力、存储、组网的需求挑战,对运营商智算布局以及算力、存储、网络、维护管理等提出了相应的策略和方案建议。

Abstract:

The computational complexity of AI training has been increasing dramatically year by year, with the required intelligent computing power growing from hundreds of millions of operations per second to tens of billions, and even reaching the level of hundreds of billions, which promotes the construction of large-scale intelligent computing centers. These centers are primarily built to meet the demand for intelligent computing power, and they differ significantly from traditional cloud resource pools in terms of layout, construction, and maintenance solutions. The industry currently lacks unified recommendations and references for the layout and detailed plans of intelligent computing centers. It analyzes the challenges of computing power, storage, and networking demands brought by the development of large models, and proposes corresponding strategies and suggestions for the layout of operators' intelligent computing, as well as computing power, storage, network, and maintenance management.

Keywords:

Artificial intelligence; Intelligent computing center; Infrastructure; Construction ideas

引用格式:童俊杰,申佳,赫罡,等. 运营商智算中心建设思路及方案[J]. 邮电设计技术, 2024(9): 68–73.

关键词:

人工智能; 智算中心; 基础设施; 建设思路

doi: 10.12045/j.issn.1007-3043.2024.09.012

文章编号: 1007-3043(2024)09-0068-06

中图分类号: TN915.5

文献标识码: A

开放科学(资源服务)标识码(OSID):



0 前言

人工智能聊天机器人 ChatGPT、AI 编程工具 GitHub CoPilot、图像生成系统 Stable Diffusion、视频生成系统 Sora 等生成式人工智能 (Generative AI, Gen-AI) 应用和工具产品的出现,为文本创建、图像视频生成、代码生成以及研发流程等工作带来了全新的智能体验,极大地提升了生产力,提高了生产水平。

Gen-AI 应用的出现离不开大模型的支持。大模

型是基于海量参数进行自监督学习的预训练模型,凭借更强的学习能力、更高的精准度以及更强的泛化能力,正在成为人工智能技术发展的焦点。随着大模型的快速成熟,其参数规模呈百万倍增长,随之而来的是算力需求的剧增,芯片算力的增长速度与模型参数规模的增长存在剪刀差,推动了超大规模智算集群的建设。

作为基础设施建设者和新质生产力的推动者,电信运营商正积极推进智算布局。本文基于大模型的发展趋势和需求,结合运营商的特定优势,提出了智算集群布局以及算力、存储、网络和维护管理方面的

收稿日期: 2024-07-11

策略和方案建议。

1 大模型的发展趋势和需求分析

1.1 大模型发展的趋势

虽然大模型的概念已经深入人心,但是目前没有明确界定标准来判定模型为小模型还是大模型。根据模型表现和模型算力需求,业界一般认为一个经过充分训练的百亿参数的模型可认定为大模型^[1]。大模型遵循的三大统计特征如下。

a) Scaling Law。模型表现依赖于模型规模、计算量和数据量,这些因素之间呈现幂律关系^[2]。

b) Chinchilla Law。模型大小和数据量要同等比例扩展,即数据量需达到参数量的20倍,模型训练结果才能达到饱和^[3]。

c) 智能涌现。只有训练计算超过 10^{22} 或训练损失足够低时,才会出现智能涌现,即在典型人工智能任务上的能力大幅提升,而和具体模型无关^[3-4]。

上述三大统计特征揭示了,随着参数模型量越来越大,模型对训练所需算力的需求越来越大,随着Sora等多模态视频模型的兴起,参数量规模剧增,OpenAI的GPT-4以及Google的Gemini Ultra都宣称达到了万亿级参数^[5]。参数量剧增导致训练所需的数据量越来越大,有预测认为,到2026年文本数据将被训练完,图像数据将在2040年前后被用完,合成数据将会是未来数据的主要来源^[6],数据量规模会再一次量级跃迁,对存储的规模和性能带来更大的挑战。此外,智算集群的规模也从百卡发展到万卡,甚至十万卡级别,对网络通信的带宽和时延要求越来越高。

1.2 算力需求和挑战

在Transformer模型结构中,算力需求与模型参数规模、数据量具有相关性,具体如表1所示。

表1 算力需求和模型参数规模

参数	符号表示	等量关系	单位和解释说明
模型参数规模	P	-	-
Tokens规模	D	$20 \times P$, 至少为模型参数的20倍	一个英文单词即可认为是一个Token,汉字可认为是一个Token;通常为百万级
训练算力	F	$6 \times P \times D^{[7]}$	FPLOPS,浮点计算次数。对于训练算力,一般认为是16位浮点计算次数
训练所需GPU卡规模	G	$F / (\text{单卡算力} \times \text{GPU利用率} \times \text{训练限制时间})$	张,用来衡量GPU卡数量。其中GPU利用率一般为30%~75%

按照上述关系,以GPT-3 175B的参数量(1 746亿)为例,其训练算力的需求为 $6 \times 174.6 \text{ B} \times 300 \text{ B} = 314\,000 \text{ EFLOPS}$ 。若采用910B(376 TFLOPS@FP16)集群,按照GPU利用率为30%,训练28天,则需要约1 150张910B GPU卡。

按照上述测算,对于万亿参数模型,则需要万卡级规模集群;对于十万亿参数模型,则需要十万卡级规模集群。因此,为了实现通用人工智能AGI,国内外互联网厂商纷纷开始“囤卡”。在算力需求倍增的同时,带来如下挑战。

a) 对显存容量和性能的挑战。GPU卡中的高带宽存储器(High Bandwidth Memory, HBM)是基于3D堆栈工艺的高性能DRAM,其本质是将多个DDR芯片堆叠后和GPU一起封装。目前,AI算力增长速度远高于显存容量和性能的增长速度,以英伟达A100、H100为例,虽然H100较A100的算力增长了将近3倍,但显存容量没增长,带宽只增长了近2倍,这对分布式显存调度提出了更高的要求^[8]。此外,当前HBM的主要厂商为海力士、三星和美光,国产GPU卡可能无法使用最新的HBM技术,显存能力演进受限。

b) 对散热和资源的挑战。从GPU卡的演进来看,GPU模型的算力和功耗成比例增长,昇腾910B芯片TDP为392 W,单台训练服务器功耗达到5.2 kW。以GPT-3为例,训练所需电量达到1 287 MW(碳排放为502 t),每天推理需要用电50万 kWh,冷却设备所需的水达到70万 L,对电力资源和水资源都是巨大挑战^[9]。

c) 对GPU跨厂家协同、跨代际演进的挑战。跨厂家GPU因为软件生态、底层算子不同,导致上层模型无法一次编译后异构执行。即使采用同一厂家的GPU,也因为不同型号GPU的算力、显存和通信能力甚至算子优化不同,共集群训练时面临性能损失、无法发挥优势的问题。

d) 对供应链保障的挑战。受美国芯片禁令的影响,国内将无法购买国外先进的GPU产品,国内GPU的产能和生态面临巨大挑战。

1.3 存储需求和挑战

AI大模型的训练和推理都会涉及到数据的存取。在训练之前的数据预处理阶段,需要对海量数据进行处理,包括格式对齐、归一化、去重、隐私保护、异常值处理等。训练阶段涉及海量小文件的训练数据存取和训练过程中参数文件的周期性保存;在推理阶段,需要读取本地存储的模型参数,并对实时样本进行处

理,输出推理结果。

AI大模型的训练和推理对存储带来的挑战如下。

a) 对数据访问性能的挑战。一方面是大量小文件带来的元数据访问挑战,另一方面则是海量小文件并发快速读取、Checkpoint周期保存参数对数据存取带来的挑战。

b) 多模态数据统一访问的挑战。对于视频和图片多模态数据输入,会对原始文件进行特征提取并以小文件的形态保存,因视频和图片原始特征复杂,处理后数据量倍增。此外,为便于后续对多模态原始和特征数据的存取,需要建立相应的快速检索机制和内容审核能力。

c) 对数据安全的挑战。复杂繁多的数据处理环节,导致数据处理存在诸多安全风险,包括数据隐私泄露、数据违规侵权、数据不可追溯、数据操作不合规等。

1.4 组网需求和挑战

在大模型训练和推理中,主要的关键网络和相关通信挑战如下。

a) 训练数据到训练计算集群的网络通信。当前数据源和数据存储主要靠近人类居住密集和业务热点区域,和自然土地资源、电力资源相对丰富的西部地区距离较远。在训练时,需将训练数据传输到西部节点,这类数据对实时性要求不高,可以采用快递硬盘或者互联网专线进行传输,以节约成本,但互联网专线因业务模式的问题,当前成本相对较高。以传输0.7 PB数据为例,采用2.5寸的3.68 TB硬盘进行数据存储,需要约50块硬盘,如果采用航空快递,1 000 km的快递成本预计为1 000元,时间预计为24 h;若租赁1 Gbit/s有保障的互联网专线,按照30 000元/月的价格(按照每月30天,每天费用为1 000元)计算,约1.5 h可完成数据传输。

b) 训练时单GPU服务器的卡间通信。为提升大模型的训练速度,一般会采用数据并行、流水线并行和张量并行,其中张量并行的并行度一般和单GPU服务器的卡数量等同,张量并行对卡间实时通信的带宽和时延带来挑战。当前卡间通信的结构主要有总线结构(例如昇腾HNCCS通信方式)和交换结构(例如英伟达NVLink通信方式)2种,总线结构因布线复杂和制程工艺要求较高,带宽和扩展性受限。国产卡较多采用总线结构,卡间互联带宽远低于国外产品,同时单机内卡规模数一般不超过8,导致张量并行度受限。

c) 训练时GPU服务器集群的通信。数据并行和流水线并行对集群内机间实时通信的带宽和时延带来挑战。为了减少计算单元的闲置,需要在流水线单元的计算周期内完成前序数据的同步和通信,一般要求在百毫秒级完成数据通信,按照十GB级的通信量,集群内机间带宽应至少达到100 Gbit/s,且随着单卡算力和吞吐的增加,对机间带宽的需求也同步增加。此外,为了避免数据重传,一般要求集群内组网为无损网络。

2 智算中心的部署策略和方案建议

2.1 绿色集约、高效布局

当前智算中心有2个典型选址策略:第一,优先选择“东数西算”枢纽节点,尤其是西部自然资源丰富的地区,土地和电力资源优势明显;第二,聚焦北、上、广、深等业务和大模型产业活跃的城市与地区^[10],靠近业务和数据。运营商因可信安全优势和充沛的骨干传输资源,在布局上具有天然优势,且基本符合上述策略,其中中国联通优先在上海、北京、广东、内蒙古开展“一基地三高地”智算梯次布局;中国移动规划部署“4+N+31+X”数据中心,在内蒙古和林格尔建设大型单体智算中心;在中国电信“2+4+31+X+O”的算力布局中,除了内蒙古和贵州2个全国性云基地,还在上海临港部署了万卡智算集群。

除布局策略外,智算中心在散热模式、机房部署方面还应充分考虑低碳绿色、集群组网,具体策略和方案建议如下。

a) 优选液冷散热模式。液冷技术可有效降低PUE,提升装机密度,且液冷节点及相关器件(例如光模块)的温度比风冷节点更低,可有效提升可靠性,降低数据中心的运维成本,提高整体经济效益。在智算资源池的建设中,智算训练服务器应优先采用液冷技术。

b) 慎用风液混合模式。GPU集群长时间运行时,GPU卡在风冷集群的温度可能达到100℃以上,为避免过热带来的故障和风险,GPU卡会进行降频处理,如果风、液冷共集群,液冷设备的GPU卡的高性能就无法发挥最大价值。因此,在智算中心建设前要做好提前规划,避免不必要的损失。

c) 单一智算集群的机房不宜过度分散。为便于无损网络组网部署和后续故障定位,建议Leaf与GPU服务器之间的距离不超过100 m,即两者最好同机房部署;建议Leaf与Spine之间的距离不超过2 km,当

Spine 与 Leaf 跨机房时,建议将所有 Spine 部署在一侧机房,尽量减少拉远的 Leaf 数量。

2.2 多元探索、异构优化

国内外主要 GPU 卡的基本情况如表 2 所示,其中英伟达 GPU 卡在算力、显存、卡间通信、生态等方面处于领先地位,AMD 和 Intel 的 GPU 卡在算力上逐步追赶,但是在生态上仍存在短板;国内则以昇腾 GPU 卡为主导,其他国产 GPU 卡不仅算力不足,在实际规模化部署上也缺乏典型案例。

受政策影响,英伟达、Intel 等国外芯片厂商的芯片面临无法在中国出售或者改版而导致性能下降的问题,而国产 GPU 则在能力和生态上存在差距。

根据现状,在算力策略和方案上的建议如下。

a) 积极发展多元算力供给。一方面,应发展多元 GPU 芯片。GPU 芯片影响单位智算算力,已经成为制约大模型发展的瓶颈,鉴于当前国内外政策和 GPU 发展水平,应积极开展多元算力芯片适配以及异构算力的管理和调度。另一方面,智算和通算需紧密结合。AI 大模型的前端访问和上层应用离不开通算,而在训练和推理过程中,AI 大模型也需要通算来运行和处理任务和数据的调度访问。

b) 兼顾多元芯片和单一芯片。多元算力异构必然带来多个智算软件生态,为模型适配和优化带来挑战,需要进行差异化考虑。对于超千亿的大模型的训练,因集群规模大、训练时间长、模型复杂,建议以单一 GPU 芯片为主;对于百亿十亿等中小模型,其集群规模在百卡左右,规模相对较小、模型适配相对简单,可以进行多元芯片探索。

c) 兼顾时效性和芯片演进。GPU 芯片在不断迭代更新,对于跨 GPU 芯片型号的组网,因为不同型号 GPU 的算力、互通、显存等能力不同,存在木桶效应,无法发挥高性能 GPU 芯片的效能,建议大规模集群选择单一芯片,同时应充分考虑建设交付周期、未来业务发展趋势、芯片演进计划等因素。对于型号落后的

GPU 训练芯片,未来随着多模态模型推理对算力需求的增加,可用于对视频生成的推理。

2.3 分层分级、存算协同

运营商本身拥有较为丰富的数据资源,包括内部 IT 系统积累的数据,也包括网络运行过程中海量的性能、告警、故障等运行数据和用户运营数据。上述海量数据通过运营商骨干网络进行传输,在汇聚、整合之后形成了特有的数据资产,此过程积累了数据清洗、数据标注、数据分析、数据可视化、数据传输等方面的技术。

鉴于上述优势和积累,对数据存储方面的策略建议如下。

a) 充分发挥大数据技术的优势。运营商经过多年技术积累,具备在异构硬件之上搭建大数据平台,数据离线批处理和实时流处理的能力,同时储备了数据清洗、数据规整、数据治理的能力。在存储方面,运营商可形成对外开放或可授权的数据资产,并将数据资产与智算服务相结合,实现数据增值。

b) 做好存力和运力的协同。对于用户数据存储热点区域,其存力需求巨大,需要提前做好和智算中心之间的运力提升,便于训练数据和推理数据的传输。

c) 在具体存储资源和能力部署上,对于清洗后的训练样本、训练中的 Checkpoint 数据等热数据,以及未清理的海量数据、训练好的模型数据等温冷数据,因为两者的访问频率和性能需求不同,需分别考虑其存储方案。

d) 对于热存储,为保障性能,采用高性能介质 NVME SSD,建议优选高速并发 NAS 协议,高带宽接入。考虑到磁盘阵列性价比和扩展性的问题,后端存储可以采用 Diskless 架构,其典型整体架构如图 1 所示。以在智算中心中广泛应用的 Lustre/GPFS 等高性能、面向对象的并行文件系统为例,在 Diskless 架构下,Lustre/GPFS 使用“盘即存储”的新型 NVMe 盘框替

表 2 国内外主要 GPU 厂家和相应型号

厂家	英伟达		Intel	AMD	华为
GPU 卡型号	H100	B200	Gaudi3	MI300	910B
发布时间	2022 年 3 月	2024 年 3 月	2024 年 4 月	2023 年 12 月	2023 年 Q2
FP16/BF16 算力(稠密)/PFLOPS	0.989	2.25	1.835	1.307	0.376
显存容量	80GB HBM3	192GB HBM3e	128GB HBM2e	192GB HBM3	64GB HBM2e
卡间互联带宽/(GBit/s)	900	1 800	1 200	896	392
软件栈	CUDA	CUDA	OneAPI	ROCm	CANN

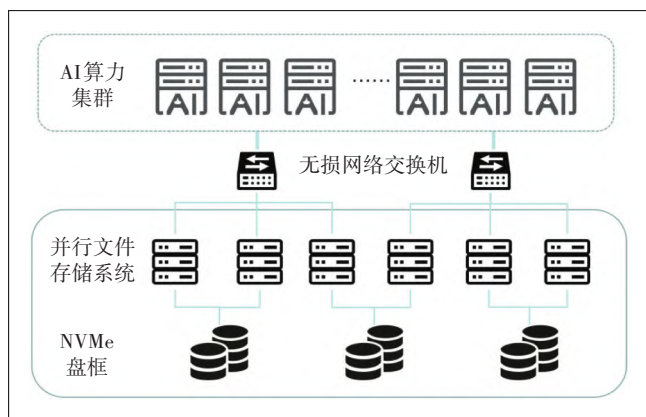


图1 采用Diskless架构存储设备的热存储方案

换存储服务器,可实现资源的池化共享、按需分配和扩展,从而提升资源利用率,降低整体成本,同时还可以隔离故障,简化运维管理。另外,从可靠性的角度来说,由于Lustre的多个OSS缺少副本机制,一个客户端或节点发生故障时,存储在该节点上的数据在重新启动前将不可访问,此时Diskless架构的高可靠优势就更为凸显。

e) 对于温冷存储,主要考虑性价比,应配置高密度、大容量的硬盘。可以选择传统的分布式对象存储,或者采用配置多盘位大容量机械硬盘的高密度新型Diskless架构存储设备。

2.4 前瞻组网、无损传输

当前运营商已经部署了布局广泛的通算资源以及运力充沛的网络资源。在部署智算中心的过程中,运营商可充分发挥已有的资源优势,主要的组网策略如下。

a) 充分考虑和东部地区数据的网络通道。智算中心的数据多来自于人口密集、经济活跃、互联网业务深入的东部热点地区,在组网中,智算中心要打通和东部热点地区的网络通道,使能训练数据、推理数据的传输。

b) 集群内的组网以终为始,长远规划。不同组网方式存在扩容上限,需以终期算力规模确定配套的网络设备,形成终期规划方案,并结合近中远期需求进行一次性建设或分期实施,在最大限度发挥算力效能的同时,预留扩展能力。

c) 广域跨集群训练要慎重。为满足训练时GPU服务器集群的通信,用于并行通信的网络平面按照1:1的收敛比进行组网,同时也因交换机缓存的限制,交换机之间的部署距离最远为2 km。如果要开展广

域跨集群组网,按照1:1的收敛比进行拉远,以1 024 GPU卡为例,在2个训练中心各部署64台GPU服务器,即512卡,按照英伟达A100或昇腾910B所需要的200G网络,参数面接入交换机下行到服务器为512个200G、上行到参数面汇聚交换机为256个400G,DC间需要256条400G链路,成本巨大;如果按照2×400 Gbit/s互联带宽(即有一定收敛比),则数据发送总时延将增加近12.5天,按GPT-3训练时间30天计算,将增加40%的训练时间,且未考虑网络设备出现数据包丢失和重传的问题。

基于大模型组网需求和上述策略,智算中心典型组网方案如图2所示,分为参数面、样本面、业务面和管理(存储)面4个平面。

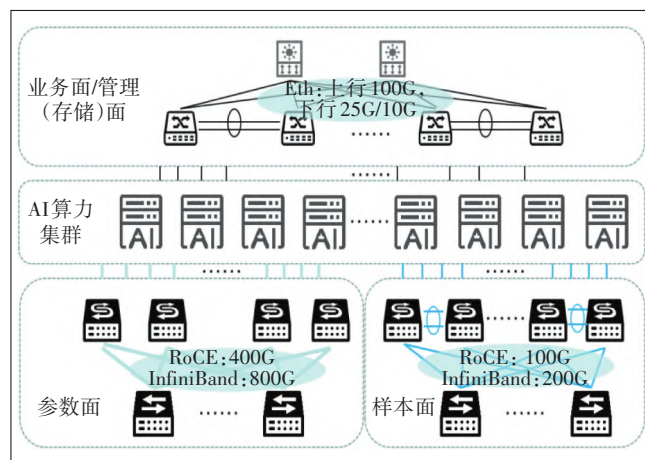


图2 智算中心典型组网方案

a) 参数面。采用RoCEv2或IB协议实现无损转发,Leaf作为接入节点的网关独立部署,通过200 GE链路与训练服务器互联。Leaf之上可以部署一层或两层Spine作为汇聚,每层网络之间按1:1进行收敛。充分利用RoCEv2和IB协议,实现流量负载均衡,防止传统基于流的五元组进行hash机制失效导致负载不均和网络吞吐下降、集群业务性能下降。

b) 样本面。采用Spine-Leaf两级无收敛架构以满足带宽需求,通信协议RoCEv2可满足时延需求,通常样本面接入交换机端口为100G。GPU服务器通过该网络平面访问高性能文件热存储。

c) 业务面/管理(存储)面。业务接入交换机端口通常为25G,且上下行收敛比一般不超过1:2.5,业务接入交换机之间的互联带宽建议大于等于单台业务接入交换机上行带宽的1/2,业务汇聚交换机之间的互联带宽建议大于等于单台业务汇聚交换机上行带宽

的1/2。

2.5 统一运维、全量监控

智算中心应具备算力、网络、存储统一运维能力,统一管理监控集群的训练服务器、存储和网络交换机设备,提供资源管理、性能监控、告警监控、光模块监控、日志分析、作业路径、健康检查、故障诊断等集群运维功能,具体功能要求建议如表3所示。

表3 智算中心运维管理功能建议

功能点	功能描述
资源管理	提供了计算、网络、链路资源的管理能力,可以在资源管理中完成对计算、网络各资源的查询、过滤等操作,便于维护人员统一查看集群的设备和部件信息
性能监控	可以对性能数据进行管理,有效地评估集群设备状态,保障集群能够提供良好的服务
告警监控	检测、记录设备的故障,便于维护人员进行问题快速定位和排障。集中管理设备上报的告警,并通过多种方式及时呈现给用户,实现设备故障的远程集中分析和处理,以保证设备正常运行,从而保证系统提供的服务和质量
日志分析	提供AI训练任务、计算任务的全栈日志可视化管理功能,帮助用户快速分析训练失败报错或故障根因;提供日志刷屏节点监控和排查异常节点的能力
作业路径	作业视图是拓扑地图上展示的与训练作业相关(参数面交换机、计算服务器、GPU卡、链路)的资源视图,为训练作业提供相关资源、路径拓扑的可视化运维管理。通过作业路径及卡间路径2个功能,可以实现与训练作业关联的计算,以及网络资源和训练作业过程中关键数据的查询管理、定位等运维操作

基于上述管理能力,形成对训前和训中的有力支撑。在训前阶段,可提前检查运行环境和组件状态,降低任务运行失败的概率;在训中阶段,具备分钟级的故障感知以及任务隔离能力,对于中断的任务,可联动断点续训,进行任务恢复。

3 结束语

随着人工智能技术的快速发展,大模型训练对智能算力的需求呈指数级增长,促进了大规模智算中心的建设。智算中心与传统云资源池在布局、建设及维护方案上存在显著差异。本文针对智算中心的建设提出了一系列策略和方案建议,以应对大模型发展带来的算力、存储和组网需求的挑战。

首先,智算中心的选址应考虑自然资源丰富的地区,同时靠近业务和数据密集区域,以确保算力资源的有效利用。其次,针对算力需求,建议发展多元算力供给,兼顾多元芯片和单一芯片的使用,同时考虑GPU芯片的迭代更新,以适应未来业务的发展趋势。在存储策略方面,运营商应充分利用大数据技术优

势,实现数据资产的增值,并做好存力和运力的协同规划。在组网方面,应充分考虑与东部热点地区的网络通道,长远规划集群内组网,并慎重考虑广域跨集群训练的可行性。最后,智算中心的运维管理应具备算网存统一运维能力,提供资源管理、性能监控、告警监控等功能,以支持大模型的高效运行。

本文的分析和建议旨在为运营商智算中心的规划和建设提供参考,推动人工智能技术的进一步发展。

参考文献:

[1] 舒文韬,李睿潇,孙天祥,等. 大模型语言模型:原理、实现与发展[J]. 计算机研究与发展,2024,61(2):351-361.

[2] KAPLAN J, MCCANDLISH S, HENIGHAN T, et al. Scaling laws for neural language models [EB/OL]. [2024-01-20]. <https://arxiv.org/abs/2001.08361>.

[3] HOFFMANN J, BORGEAUD S, MENSCH A, et al. Training compute-optimal large language models [C]//Proceedings of the 36th International Conference on Neural Information Processing Systems. Red Hook:Curran Associates Inc.,2024:30016-30030.

[4] DU Z X, ZENG A H, DONG Y X, et al. Understanding emergent abilities of language models from the loss perspective [EB/OL]. [2024-01-20]. <https://arxiv.org/abs/2403.15796>.

[5] Ray T. Gen AI training costs soar yet risks are poorly measured, says Stanford AI report [EB/OL]. [2024-01-20]. <https://www.zdnet.com/article/gen-ai-training-costs-soar-even-as-risks-are-poorly-measured-says-stanford-ai-report/>.

[6] 李国杰. 大数据与计算模型[J]. 大数据,2024,10(1):9-16.

[7] LENNART, SEVILLA J, HOBBAHN M, et al. Estimating training compute of deep learning models [EB/OL]. [2024-01-20]. <https://www.alignmentforum.org/posts/HvqQm6o8KwnxbdmhZ/estimating-training-compute-of-deep-learning-models>.

[8] 冯杨洋,汪庆,谢旻晖,等. 从BERT到ChatGPT:大模型训练中的存储系统挑战与技术发展[J]. 计算机研究与发展,2024,61(4):809-823.

[9] Stanford University Human-Centered Artificial Intelligence. Artificial intelligence index report 2023 [R/OL]. [2024-01-20]. https://aiindex.stanford.edu/wp-content/uploads/2023/04/HAI_AI-Index-Report_2023.pdf.

[10] 殷凯凯. 基于电信运营商视角的智算中心规划建设关键点分析及建议[J]. 现代信息科技,2024,8(1):22-27.

作者简介:

童俊杰,高级工程师,博士,主要从事云计算、智算规划与方案等工作;申佳,工程师,学士,主要从事云计算、智算方面的咨询、规划和设计工作;赫昱,高级工程师,博士,主要从事云计算、智算规划与方案等工作;张奎,正高级工程师,学士,主要从事云计算、智算方面的咨询、规划和设计工作。